

SD2026040000061

Evaluasi Pengelompokan Perangkat Elektronik Berbasis *Multi-View Frozen Embedding*
dan Analisis Material Visual Menggunakan Apple DMS46
Konsistensi cluster, transfer eksternal, dan profil material visual

**SEMIFINAL
BIG DATA CHALLENGE
2026**



**DIKTISAINTEK
BERDAMPAK**





DIKTISAINTEK
BERDAMPAK



Evaluasi Pengelompokan Perangkat Elektronik Berbasis *Multi-View Frozen Embedding* dan Analisis Material Visual Menggunakan Apple DMS46

Abstrak

Foto sampah elektronik dapat memberi informasi tentang jenis perangkat dan material yang terlihat, tetapi perbedaan proses akuisisi juga dapat memengaruhi kelompok yang terbentuk dari *embedding*. Penelitian ini mengevaluasi pengelompokan perangkat berbasis *multi-view frozen embedding* dan penggunaan Apple DMS46 untuk membaca profil material visual. Data internal berisi 4.179 citra, yaitu 3.579 citra untuk membentuk *cluster* dan 600 citra *holdout* untuk evaluasi material. Sebelum ekstraksi fitur, *resize* dan *re-encoding* JPEG seragam menurunkan AUC prediksi asal foto dari *embedding* SigLIP2 dari 0,993 menjadi 0,875. *Embedding* dari delapan *frozen backbone* kemudian digabung melalui PCA dan *concatenation*, lalu dikelompokkan dengan K-Means. Setelah penelusuran K=4 hingga 24, adaptasi chooseR memilih K=12 dalam rentang lanjutan K=12 hingga 16. Pada K tersebut, rata-rata ARI terhadap *medoid* dari 100 *seed* mencapai 0,99747 dengan 95% CI [0,99564–0,99931]. Dalam evaluasi 710 citra Bangladesh dengan pemetaan *cluster* ke *class* yang ditetapkan dari data internal, Fusion-L2 memperoleh *strict Macro Top-1* sebesar 0,888 dan CI selisih terhadap RADIO [0,029–0,070]. DMS46 mencapai *macro AUROC* 0,732 pada 1.018 citra Bangladesh, sementara penambahan indikator *cluster* menurunkan *error* prediksi deskriptor material pada *holdout* internal sebesar 11,45% setelah asal foto dan statistik akuisisi diperhitungkan. Hasil ini mendukung konsistensi kelompok perangkat, transfer pada empat *class* evaluasi, dan hubungan *cluster* dengan tampilan material. Namun, Fusion-L2 berbeda dari partisi Fusion yang diuji stabilitasnya, sedangkan komposisi material sesungguhnya dan efektivitas pemilahan fisik belum diuji.

Kata kunci: *discovery* perangkat, *frozen embedding*, *multi-view fusion*, stabilitas *clustering*, *external validation*.

PENDAHULUAN

Sampah elektronik atau *e-waste* merupakan peralatan listrik dan elektronik yang telah dibuang oleh pemiliknya. Global *E-waste* Monitor 2024 mencatat bahwa dunia menghasilkan 62 juta ton sampah elektronik pada 2022, meningkat 82% dibandingkan 2010. Dari jumlah tersebut, hanya 22,3% yang tercatat dikumpulkan dan didaur ulang melalui sistem resmi yang memenuhi ketentuan pengelolaan lingkungan. Pengelolaan



DIKTISAINTEK
BERDAMPAK



yang tidak sesuai dapat melepaskan zat berbahaya, termasuk merkuri dan bahan penghambat nyala berbromin, ke lingkungan (Baldé et al., 2024). Persoalannya mencakup kehilangan material yang dapat dipulihkan serta risiko kesehatan dan lingkungan.

Pemilahan sampah elektronik melibatkan pengenalan perangkat dan pemeriksaan materialnya. Pedoman Konvensi Basel untuk peralatan komputer menjelaskan bahwa perangkat diperiksa dan dipilah sebelum pembongkaran, kemudian komponennya dipisahkan untuk pengolahan material (Secretariat of the Basel Convention, 2025). Dalam tahapan tersebut, foto dapat membantu mengenali jenis perangkat dan material permukaannya. Komposisi seluruh perangkat dan keamanan penanganannya tetap memerlukan pemeriksaan lain.

Namun, kemiripan foto tidak selalu menunjukkan kemiripan perangkat. Jaipuria et al. (2022) menunjukkan bahwa *clustering* citra dapat mengikuti pencahayaan, bayangan, dan lingkungan pengambilan gambar. Temuan tersebut menjadi alasan untuk memeriksa isi tiap kelompok dan menguji apakah hasil pengelompokan tetap bermakna pada sumber foto lain.

Penelitian Terkait

Penelitian sebelumnya telah menggunakan deteksi objek untuk mengenali komponen elektronik. Rajeev et al. (2025), misalnya, membandingkan YOLOv5, YOLOv7, dan YOLOv8 pada tujuh kategori komponen dan melaporkan mAP50 sebesar 0,821 serta mAP50–95 sebesar 0,678 untuk YOLOv8. Deteksi objek memberi lokasi dan kategori komponen, tetapi *training* memerlukan anotasi sesuai kategori yang ditetapkan. Karena data internal penelitian ini belum memiliki *label* fungsi perangkat, pertanyaannya adalah kelompok apa yang muncul dari kemiripan visual tanpa menetapkan *label* tersebut pada setiap citra sejak awal.

Untuk menelusuri kemiripan tersebut tanpa melatih ulang *backbone* pada data internal, penelitian ini menggunakan *frozen embedding*. DINOv2 mempelajari fitur melalui *self-supervised learning*, sedangkan SigLIP2 menggabungkan *image-text pretraining* dengan objektif visual tambahan (Oquab et al., 2024; Tschannen et al., 2025). Dalam *benchmark* yang menggabungkan *embedding* CLIP dan DINOv2, TURTLE memperoleh hasil lebih tinggi daripada K-Means (Gadetsky et al., 2024). Hasil tersebut memberi alasan untuk membandingkan K-Means dengan optimasi *multi-view* pada data penelitian ini.



DIKTISAINTEK
BERDAMPAK



Selain pemilihan *backbone*, kondisi citra yang masuk ke model juga perlu diperhatikan. Ehrlich et al. (2021) menemukan penurunan kinerja pada beberapa tugas *vision* ketika kompresi JPEG meningkat, sedangkan Jaipuria et al. (2022) menunjukkan bahwa kondisi foto dapat memengaruhi hasil *clustering*. Kedua temuan ini membantu menafsirkan pemisahan yang muncul pada pengelompokan awal. Model dapat menggunakan petunjuk visual yang tidak berkaitan dengan jenis perangkat, sebagaimana dibahas dalam *shortcut learning* (Geirhos et al., 2020).

Pada percobaan *clustering* sebelum *input* diseragamkan, *cluster* yang terbentuk terpisah kuat menurut sumber foto. Dalam partisi diagnostik $K=16$, dua *cluster* yang sama-sama memuat perangkat komputer bahkan terpisah menurut sumbernya. Temuan ini mendorong *exploratory data analysis* (EDA) untuk menelusuri penyebab pemisahan tersebut. Sebanyak 2.815 citra berukuran 150×150 piksel, sedangkan 1.364 citra lainnya memiliki resolusi lebih tinggi. *Probe* linier yang memprediksi asal foto dari *embedding* SigLIP2 menghasilkan AUC 0,993. Artinya, asal foto mudah dikenali dari representasinya, tetapi angka itu saja belum menunjukkan apakah penyebabnya adalah isi perangkat, ukuran citra, atau proses akuisisi lain.

Rumusan Masalah

1. Apakah *input* seragam menurunkan AUC prediksi asal foto?
2. Bagaimana kualitas dan stabilitas *cluster* K-Means Fusion?
3. Apakah pemetaan *cluster* internal berlaku pada citra Bangladesh?
4. Apakah profil DMS46 membedakan *class* material dan berkaitan dengan *cluster*?

Tujuan Penelitian

1. Mengukur AUC asal foto sebelum dan sesudah *input* diseragamkan.
2. Membandingkan K-Means Fusion dengan estimator lain, memilih K acuan, dan mengukur stabilitas *cluster*.
3. Mengukur *strict Macro Top-1* pada empat *class* perangkat Bangladesh.
4. Mengukur AUROC DMS46 dan penurunan *error* profil material pada *holdout* internal setelah kontrol akuisisi.

Manfaat Penelitian

Secara ilmiah, penelitian ini menyediakan pembandingan empiris antara K-Means Fusion dan metode yang lebih kompleks pada citra multisumber, disertai pengujian pengaruh asal foto dan stabilitas *cluster*. Pemetaan *cluster* internal mencapai *strict Macro Top-1*



DIKTISAINTEK
BERDAMPAK



sebesar 0,888 pada empat *class* Bangladesh, sedangkan prediksi DMS46 membedakan *class* material dengan *macro AUROC* 0,732. Kedua informasi tersebut dapat menjadi dasar pengembangan sistem bantu pemeriksaan awal perangkat dan material yang terlihat, meskipun keputusan pemilahan dan nilai materialnya belum diuji.

METODOLOGI

Dataset

Data internal berisi 3.979 citra *data train* berlabel *electronic* dan 200 citra *data test* yang diprediksi *electronic* oleh sistem penyisihan, bukan berdasarkan *ground truth* panitia. Sebanyak 3.579 citra digunakan untuk membentuk *cluster*, sedangkan 600 citra disisihkan sebelum interpretasi sebagai *holdout* internal. PCA, *centroid*, dan model regresi material di-*fit* pada 3.579 citra tersebut, lalu dukungan deskriptor material dinilai pada *holdout* yang tidak ikut *fitting*. Pembagian ini tidak memerlukan *label* fungsi perangkat dan dirangkum pada Tabel 1.

Tabel 1. Populasi dan peran evaluasi

Populasi	N	Peran
Internal train <i>electronic</i>	3.979	<i>Label</i> penyisihan
Internal test predicted <i>electronic</i>	200	<i>Label</i> prediksi
Internal <i>discovery</i>	3.579	<i>Fitting</i> dan seleksi
Internal <i>holdout</i>	600	Evaluasi deskriptor
Bangladesh <i>annotated</i>	2.153	Data eksternal
Bangladesh, 4 <i>class</i> perangkat	710	Validasi eksternal
Bangladesh, 4 <i>class</i> material	1.018	Evaluasi DMS46

Untuk menilai penerapan *cluster* pada sumber foto lain, penelitian ini menggunakan Custom Bangladeshi *E-Waste Image Dataset* for Object Detection and Recognition versi 1 (Afrin & Azmi, 2025), berlisensi CC BY 4.0. Empat dari 2.157 citra memiliki anotasi kosong dan dikecualikan. Evaluasi pengelompokan menggunakan 710 citra dari *class* baterai, ponsel, PCB, serta gabungan *keyboard* dan *mouse*. *Keyboard* dan *Mouse* digabung karena *cluster* keduanya dipetakan ke kelompok evaluasi yang sama, sedangkan 1.443 citra lainnya berada di luar cakupan pemetaan. Evaluasi material menggunakan 1.018 citra berbeda dari *class* kaca, logam, kertas, dan plastik.



DIKTISAINTEK
BERDAMPAK



Preprocessing Citra dan Ekstraksi Fitur

Pemisahan sumber foto yang muncul pada *clustering* awal ditelusuri melalui EDA. Ukuran citra diperiksa lebih dulu, lalu tabel kuantisasi JPEG diperiksa setelah uji *resize* belum cukup mengurangi pemisahan. Untuk mengukur seberapa jelas asal foto tercermin dalam representasi, *probe* regresi logistik memprediksi asal citra dari *embedding* SigLIP2 melalui *cross-validation* tiga fold. Sebelum digunakan oleh *probe*, fitur dinormalisasi L2, direduksi dengan PCA menjadi 128 dimensi pada seluruh data, lalu dinormalisasi kembali. AUC 0,5 setara tebakan acak, sedangkan nilai mendekati satu menunjukkan asal citra mudah dikenali dari representasi tersebut.

Setelah perbedaan kedua korpus diperiksa, citra diproses dengan konfigurasi *input* yang sama. Setiap citra di-*crop* menjadi persegi, di-*resize* dengan LANCZOS menjadi 150 × 150 piksel, lalu di-*encode* ulang menjadi JPEG *quality* 75 dengan *subsampling* 4:2:0 sebelum *transform native* tiap *backbone* diterapkan. *Label* asal citra digunakan untuk evaluasi, bukan untuk menentukan perlakuan tiap korpus.


Fitur dari citra yang telah diproses diekstraksi dengan delapan *backbone*, yaitu DINOv3, C-RADIOv4, AIMv2, SigLIP2, DINOv2, SigLIP, ConvNeXtV2, dan EVA02. Bobot semuanya tetap saat digunakan pada data internal maupun Bangladesh. ConvNeXtV2 dan EVA02 memang telah menjalani *fine tuning* ImageNet oleh pengembangnya, tetapi penelitian ini tidak menggunakan bobot *fine tuning* tahap penyisihan. DINOv2 dan SigLIP disertakan untuk membandingkan generasi *backbone*, bukan karena manfaat tiap *view* dalam *fusion* sudah terbukti terpisah. Identitas *checkpoint* tersedia di Lampiran B. Untuk menggabungkan kedelapan *view*, konfigurasi Fusion menormalisasi L2 setiap *embedding* dan mereduksinya dengan PCA menjadi 32 dimensi. Hasilnya digabung menjadi 256 dimensi, dinormalisasi L2, direduksi menjadi 100 dimensi, lalu dinormalisasi kembali. PCA menggunakan *randomized solver* dengan *random state* 0 tanpa *whitening*. Varian Fusion-L2 menambahkan normalisasi L2 setelah PCA per *view*. Konfigurasi dimensi ini belum diuji sebagai pilihan optimum.

$$z_i = N(P_{100}(N([P_{32,v}(N(E_{iv}))]_{v=1}^8))) \quad (1)$$

Dalam Persamaan (1), E_v adalah *embedding view* v , N normalisasi L2, dan P *transform* PCA yang di-*fit* pada *discovery*. Fusion menghasilkan ruang fitur yang dikelompokkan K-Means dengan meminimalkan jumlah kuadrat jarak ke *centroid* (Lloyd, 1982). Prompt

teks dan deskriptor material tidak masuk fungsi objektif. Proyeksi t-SNE hanya digunakan untuk visualisasi.

Gambar 1 memperlihatkan pembentukan *cluster* dari citra internal. Fusion digunakan untuk studi stabilitas dan contoh *cluster*, sedangkan Fusion-L2 digunakan untuk evaluasi pada Bangladesh dan analisis hubungan *cluster* dengan material. ARI antara partisi kedua varian pada K=12 mencapai 0,974794, sehingga hasil evaluasi Fusion-L2 tidak otomatis berlaku untuk partisi Fusion.



Gambar 1. Alur pengelompokan perangkat elektronik pada data internal.

Pemilihan Metode dan Jumlah *Cluster*

Setelah ruang fitur dibentuk, K-Means Fusion dibandingkan dengan beberapa alternatif untuk menilai manfaat metode yang lebih kompleks pada data ini. Pembanding meliputi K-Means RADIO sebagai *single-view*, PAM pada ruang *fused*, MCSF dengan *spectral loss* dan *contrastive alignment* (Cai et al., 2026), serta TURTLE yang mengoptimalkan partisi *multi-view* (Gadetsky et al., 2024). MCSF dan TURTLE dijalankan melalui *adapter* lokal. Kualitas hasil dibaca dari *silhouette* untuk kekompakan *cluster*, ARI untuk kesepakatan *assignment*, dan NMI untuk hubungan *cluster* dengan asal foto. *Adjusted coverage* mengukur keragaman konsep fungsi setelah dikurangi hasil pengacakan skor di tiap sumber foto. Konsep tersebut menjadi diagnostik setelah *clustering*, bukan *ground truth*.

Jumlah *cluster* ditelusuri dalam dua tahap. Penelusuran awal mencakup K=4 hingga 24, lalu K=12 hingga 16 diperiksa lebih lanjut menggunakan 100 *subset* berisi 80% data *discovery* dengan *seed* 20260927. Pada setiap *subset*, PCA dan *clustering* di-fit ulang. Frekuensi *co-clustering* dihitung ketika kedua citra masuk *subset* dan dikurangkan dari satu untuk membentuk jarak *consensus*. *Silhouette* pada jarak ini dihitung terhadap *medoid* partisi penuh, mengikuti prinsip *resampling chooseR* pada data *single-cell* (Patterson-Cross et al., 2021).



DIKTISAINTEK
BERDAMPAK




Untuk memilih K dari rentang lanjutan, implementasi lokal menggunakan 25.000 *percentile bootstrap* atas median skor per citra. Batas bawah CI tertinggi antarkandidat menjadi *threshold*, lalu dipilih K dengan *cluster* terbanyak yang median skornya melampaui batas tersebut. Prosedur ini disebut adaptasi chooseR karena metode aslinya menggunakan distribusi skor per *cluster* dan CI BCa. *Silhouette consensus* menilai konsistensi setelah *subsampling*, sedangkan *silhouette embedding* menilai kekompakan ruang fitur.

Selain perubahan sampel, pengaruh inisialisasi K-Means diperiksa melalui 100 *seed* dengan $n_init=20$ pada setiap K lanjutan. Partisi *medoid* dipilih dari *run* yang rata-rata ARI-nya tertinggi terhadap *run* lain. ARI mengukur kesepakatan *assignment*, bukan ketepatan *label* perangkat, sedangkan Jaccard menilai perubahan tiap *cluster* setelah *subsampling*. Stabilitas dibandingkan dengan *permutation null assignment*, tetapi belum dengan null yang mempertahankan kovarians *embedding*.

Interpretasi dan Evaluasi

Untuk membantu interpretasi, setiap kelompok diberi nama sementara setelah proses *clustering* selesai. Penamaan mengacu pada objek yang terlihat dalam citra dekat *centroid*, dengan skor konsep visual sebagai petunjuk tambahan. Gambar 6 mengikuti *assignment medoid* $K=12$ dan menampilkan dua contoh yang mudah dikenali dari 18 anggota terdekat ke *centroid* pada ruang Fusion 100 dimensi. Karena contoh tersebut berasal dari sekitar pusat *cluster*, namanya menggambarkan pola visual yang diperiksa, bukan kategori mayoritas yang telah dibuktikan untuk seluruh anggota.

Untuk menilai apakah pengelompokan dapat diterapkan pada sumber foto lain, citra Bangladesh diproses menggunakan *transform* Fusion-L2 atau RADIO yang di-*fit* pada data internal. Setiap citra kemudian ditempatkan pada *centroid* terdekat dari seluruh *cluster*, seperti ditunjukkan pada Gambar 2. Pemetaan *cluster* ke empat *class* perangkat ditetapkan dari profil visual data internal tanpa penyesuaian terhadap *label* Bangladesh, dan *cluster* tanpa pemetaan dihitung sebagai *error*. *Strict Macro Top-1*, yaitu rata-rata *recall* keempat *class*, dibandingkan dengan *paired bootstrap* pada citra yang sama. Skor tersebut berbeda dari macro-F1 yang memakai pemetaan *in-sample*.



Gambar 2. Penempatan citra Bangladesh ke *cluster* dari data internal.

Selain kelompok perangkat, penelitian ini menganalisis material yang terlihat melalui *dense material segmentation* Apple DMS46 (Upchurch & Niu, 2022). Prediksi 46 *class* diringkas menjadi enam kategori, yaitu kaca, logam, kertas/karton, plastik, karet, dan lainnya. Proporsi area piksel yang diprediksi pada setiap kategori membentuk profil material citra, sebagaimana digambarkan pada Gambar 3. Untuk Bangladesh, area dihitung pada gabungan *region of interest* (ROI) dari anotasi YOLO, dengan *polygon* diubah menjadi *enclosing bounding box*. AUROC dan *average precision* menilai kemampuan profil tersebut membedakan empat *class* material pada *dataset*. *Argmax* tidak menjadi metrik utama karena satu ROI dapat mengandung beberapa material.



Gambar 3. Pembentukan profil material visual dari citra internal dan Bangladesh.

Pada data internal, analisis dilanjutkan untuk menilai apakah *cluster* menambah informasi tentang profil material. Proporsi area lebih dulu ditransformasi dengan akar kuadrat dan dinormalisasi L2. Model *baseline* menggunakan asal citra serta statistik akuisisi dan latar, sedangkan model *full* menambahkan indikator *cluster*. Kedua model di-*fit* pada *discovery* dan dinilai pada *holdout* internal. Perubahan *error* prediksinya dirumuskan dalam Persamaan (2).

$$R^2_{\text{incremental}} = 1 - \text{SSE}_{\text{full}} / \text{SSE}_{\text{baseline}} \quad (2)$$

Persamaan (2) membandingkan jumlah kuadrat *error* prediksi (SSE) model *full* dan *baseline* pada target hasil transformasi akar. $R^2_{\text{incremental}}$ menunjukkan penurunan *error* relatif terhadap *baseline*, bukan proporsi total *variance* yang dijelaskan. CI dihitung melalui *bootstrap holdout* terstratifikasi *web/field*, sedangkan *permutation null* diperoleh dari 999 pengacakan *assignment cluster* di dalam asal citra. Ketidakpastian ini bersyarat pada model dan partisi yang telah di-*fit*, sehingga tidak mencakup pemilihan seluruh kandidat.




DIKTISAINTEK
BERDAMPAK



HASIL DAN PEMBAHASAN

Analisis Eksploratif Data dan *Preprocessing*

Setelah *clustering* awal memperlihatkan pemisahan menurut sumber foto, EDA menemukan perbedaan ukuran antara kedua korpus. Karena itu, *resize* diuji lebih dulu. Seperti terlihat pada Gambar 4, langkah ini hanya menurunkan AUC *probe* SigLIP2 dari 0,993 menjadi 0,983, sehingga asal foto masih mudah dikenali dari *embedding*. Pemeriksaan kemudian beralih ke tabel kuantisasi JPEG. Sebanyak 2.814 dari 2.815 citra *web* memiliki tabel identik dengan standar IJG *quality* 75 dan *subsampling* 4:2:0, sedangkan tabel foto beresolusi tinggi lebih beragam. Setelah *resize* disertai *re-encoding* JPEG seragam, AUC turun menjadi 0,875.



Gambar 4. AUC prediksi asal foto pada data internal dan pasangan *cluster* 08/09 dari partisi awal.

Untuk menilai hasil pada foto dengan jenis objek yang lebih serupa, *probe* juga diuji pada 380 foto perangkat komputer dari *cluster* 08 dan 09 pada partisi awal. Keduanya memperlihatkan monitor, *keyboard*, dan *mouse*, tetapi terutama berasal dari sumber foto yang berbeda. Setelah *resize* dan *re-encoding* JPEG, AUC pasangan ini turun dari 0,999 menjadi 0,523, mendekati nilai acak 0,500. Artinya, asal foto jauh lebih sulit dibedakan di antara citra berkonten sejenis. Namun, AUC seluruh data masih 0,875, sehingga perbedaan antar-sumber belum hilang secara global dan mungkin juga berkaitan dengan perangkat atau latar.

Kedua langkah tersebut digunakan sebelum ekstraksi fitur karena *resize* saja tidak cukup menurunkan keterbedaan asal foto. Hasil *probe* tetap tidak menetapkan JPEG sebagai satu-satunya penyebab perbedaan *cluster*.

Perbandingan Metode dan Pemilihan K

Setelah *input* diproses dengan konfigurasi yang sama, delapan keluarga metode ditelusuri. Tabel 2 merangkum delapan estimator terpilih pada K=12 agar K-Means Fusion dapat



DIKTISAINTEK
BERDAMPAK



dibandingkan dengan *single-view*, estimator *centroid* lain, dan beberapa metode *multi-view* pada jumlah *cluster* yang sama.

Tabel 2. Perbandingan terpilih pada K=12

Estimator	Sil.	ARI awal	Coverage adj.	NMI asal
K-Means Fusion	0.305	1.000	0.355	0.160
K-Means RADIO	0.300	0.958	0.316	0.154
PAM Fusion	0.302	1.000	0.265	0.153
Evidence accumulation	0.300	0.931	0.369	0.173
MCSF MB3	0.300	0.988	0.262	0.169
AMF MB8	0.276	1.000	0.350	0.142
TURTLE MB8	0.254	0.953	0.265	0.159
FGW MB4	0.243	0.977	0.150	0.012

Semua baris memakai K=12 dan *seed* 42 untuk *silhouette*, *coverage*, dan NMI. ARI awal dihitung dari tiga *seed*, berbeda dari pemeriksaan 100 *seed* pada Fusion. *Coverage* memakai konsep visual *post-hoc*. MCSF, AMF, TURTLE, dan FGW dijalankan melalui *adapter* lokal. Hasil kandidat lain tersedia di repositori.

Dari sisi kekompakan, K-Means Fusion memperoleh *silhouette* 0,305, sedangkan PAM, MCSF, dan evidence accumulation berada pada 0,300–0,302. Namun, evidence accumulation memberi *adjusted coverage* lebih tinggi (0,369 dibanding 0,355). FGW MB4 lebih lemah pada *silhouette* dan *coverage* (0,243 dan 0,150), walaupun NMI asal fotonya lebih rendah daripada K-Means Fusion (0,012 dibanding 0,160). Dengan hasil tersebut, K-Means digunakan sebagai acuan karena kekompakannya pada perbandingan ini, bukan karena unggul pada setiap ukuran. Ketika tiap metode memakai K pilihannya sendiri, evidence accumulation bahkan mencapai *silhouette* 0,314 dibanding 0,312 untuk K-Means Fusion. Perbedaan implementasi dan *dataset* membatasi perbandingan angka ini dengan hasil TURTLE pada Gadetsky et al. (2024).

Perbandingan *backbone* membantu menjelaskan mengapa versi lebih baru tidak otomatis menggantikan versi sebelumnya pada data ini. Pada K=12 dan *seed* 42, *silhouette single-view* DINOv3 mencapai 0,286 dibanding DINOv2 sebesar 0,258. Arah perbandingannya berbalik pada SigLIP, yaitu 0,295 dibanding SigLIP2 sebesar 0,278. Sebagai pemeriksaan jumlah *view* pada metode lain, TURTLE K=12 mencapai 0,248 dengan DINOv3, RADIO, SigLIP2, dan ConvNeXtV2, lalu 0,254 dengan delapan *view*. Hasil tersebut




DIKTISAINTEK
BERDAMPAK



belum mengisolasi manfaat masing-masing *backbone* dalam Fusion dengan K-Means. Karena itu, delapan *view* dilaporkan sebagai konfigurasi yang diuji, bukan kombinasi optimal.

Penelusuran awal berdasarkan *silhouette embedding* dan indikator semantik setelah *clustering* mengarah ke $K=14$. Namun, kedua ukuran itu belum menunjukkan apakah *assignment* bertahan ketika data berubah. Karena itu, $K=12$ hingga 16 diperiksa lagi melalui *resampling*. Adaptasi chooseR memilih $K=12$ sebagai jumlah *cluster* acuan. Gambar 5 memisahkan hasil penelusuran awal dari pengujian stabilitas tersebut.



Gambar 5. Evaluasi K pada Fusion melalui *silhouette* (a), *adjusted coverage* (b), *consensus chooseR* (c), dan stabilitas *seed* (d).


Adaptasi chooseR menghasilkan *threshold* 0,997354. Pada $K=12$, tujuh *cluster* melampauinya, sedangkan K lain memiliki paling banyak lima. $K=12$ juga memberi rata-rata ARI terhadap *medoid* sebesar 0,99747 dengan 95% CI [0,99564–0,99931], dan 99 dari 100 *run* mencapai $ARI \geq 0,95$. Sebagai pembandingan, $K=14$ memperoleh rata-rata ARI 0,97730 dengan 69 *run* melewati batas tersebut. Pada tingkat *cluster*, median Jaccard $K=12$ mencapai 0,9955 dan tidak ada kuantil 2,5% yang jatuh di bawah 0,60.

$K=12$ berada pada batas bawah pemeriksaan lanjutan, sehingga pemilihannya belum menetapkan jumlah *cluster* yang benar atau optimum global. Pada penelusuran awal, *silhouette* naik dari 0,305 pada $K=12$ menjadi 0,321 pada $K=16$, tetapi *adjusted coverage* turun dari 0,355 menjadi 0,258. Pada $K=18$ hingga 24, *silhouette* turun dari 0,309 menjadi

0,257 dan *adjusted coverage* dari 0,222 menjadi 0,132. Penambahan *cluster* di atas $K=16$ terutama menghasilkan pengulangan deskriptor konsep perangkat, bukan bukti kategori baru yang stabil. NMI terhadap asal citra pada $K=12$ masih 0,160, sehingga *assignment* yang stabil tetap dapat berkaitan dengan asal foto.

Interpretasi Hasil *Clustering*

Setelah stabilitas *cluster* diperiksa, Gambar 6 memperlihatkan pola visual melalui dua contoh dari tiap *cluster*. Contohnya mencakup PCB, mesin cuci, *mouse*, laptop, ponsel, *printer*, perangkat *audio*, baterai, microwave, TV, dan *keyboard*. Pada C08, citra dekat *centroid* justru memperlihatkan tumpukan berbagai perangkat, sehingga *cluster* ini diberi nama deskriptif “tumpukan perangkat”. Nama tersebut merangkum contoh yang diperiksa, bukan proporsi jenis objek pada seluruh anggota C08.



Gambar 6. Dua citra dekat *centroid* untuk tiap *cluster* Fusion $K=12$.

C02 berisi 293 citra dengan contoh *mouse*, sedangkan C11 berisi 274 citra dengan contoh *keyboard*. Median Jaccard keduanya adalah 1,000 dan 0,9954, dengan kuantil 2,5% sebesar 0,9936 dan 0,9008. Keduanya tetap terpisah dalam pengujian *subsampling*, walaupun sama-sama digunakan untuk memberi *input* ke komputer. Hasil ini



DIKTISAINTEK
BERDAMPAK




menunjukkan pemisahan visual yang stabil, tetapi belum membuktikan bahwa algoritma memahami hubungan fungsi keduanya.

Pada resolusi yang lebih rinci, *cluster* layar C10 pada $K=12$ terutama terpecah menjadi C05 dan C12 pada $K=16$. Sebanyak 142 dari 145 anggota C05 dan 135 dari 137 anggota C12 berasal dari C10. Contoh dekat *centroid* memperlihatkan televisi tabung pada C05 dan layar datar pada C12 (Gambar C1). Kedua *cluster* juga relatif stabil saat sampel berubah, dengan kuantil 2,5% Jaccard sebesar 0,936 dan 0,955. Proporsi foto *web* masing-masing 0,814 dan 0,839, dibanding 0,832 pada C10. Bukti ini mendukung dua pola visual di pusat *cluster*, tetapi belum mengukur *purity* seluruh anggota atau memisahkan televisi dari monitor secara konsisten.

Pemisahan layar pada $K=14$ kurang stabil dibanding dua *cluster* layar pada $K=16$ karena sekitar 40–41% *subset* menghasilkan Jaccard di bawah 0,60. Pemecahan laptop pada $K=16$ juga bertahan, tetapi proporsi sumber fotonya berbeda sehingga makna semantiknya belum jelas. Pemeriksaan konsep visual pun belum mendukung stopkontak, steker, atau terminal listrik sebagai *cluster* tersendiri.

Validasi Eksternal

Ketika *transform* dan *centroid* yang di-fit pada data internal diterapkan pada 710 citra Bangladesh, *strict Macro Top-1 Fusion-L2* $K=12$ mencapai 0,888 (95% CI [0,865–0,913]). RADIO $K=12$ memperoleh 0,838 (95% CI [0,813–0,864]), sehingga selisih berpasangannya sekitar 0,050 dengan CI [0,029–0,070] (Gambar 7). Untuk Fusion-L2, *null permutation* menghasilkan kuantil 95% sebesar 0,264 dan $p=0,001$.



Gambar 7. Evaluasi pada 710 citra Bangladesh melalui *strict Macro Top-1* (a) dan *recall per class* (b).



DIKTISAINTEK
BERDAMPAK



Selisih agregat terutama berasal dari baterai, dengan *recall* Fusion-L2 sebesar 0,878 dibanding RADIO 0,628. RADIO sedikit lebih tinggi pada ponsel, PCB, serta *keyboard* dan *mouse*, sehingga peningkatan Fusion-L2 tidak merata pada seluruh *class*. Sebanyak 95,8% citra mendapat *assignment* ke *centroid* yang memiliki pemetaan kelompok, sedangkan 4,2% sisanya tetap dihitung sebagai *error*. Seluruh *centroid* disertakan agar *accuracy* tidak meningkat hanya karena pencarian dibatasi pada *cluster* yang telah dipetakan.

Hasil transfer ini terbatas pada empat *class* evaluasi perangkat karena 1.443 citra Bangladesh di luar cakupan pemetaan tidak masuk perhitungan *accuracy*. Pengujian pada *dataset* lain memberi pemeriksaan generalisasi tambahan (Recht et al., 2019), tetapi *label* Bangladesh hanya menunjukkan kategori objek. Karena itu, skor transfer belum memvalidasi kondisi limbah atau seluruh jenis perangkat pada data internal, dan independensi citra lintas *dataset* juga belum dipastikan sepenuhnya.

Analisis Deskriptor Material

Analisis material kemudian memeriksa apakah *cluster* memberi informasi tambahan tentang profil material setelah asal citra dan statistik akuisisi diperhitungkan. Pada 600 citra *holdout* internal, penambahan indikator *cluster* Fusion-L2 $K=12$ menurunkan SSE sebesar 11,45% relatif terhadap *baseline*, dengan 95% CI [8,89%–14,09%]. Ketika kategori lainnya dikeluarkan dan proporsi lima material dinormalisasi ulang, penurunan menjadi 15,28% dengan CI [12,10%–18,45%]. Dua citra tanpa area prediksi pada kelima material dikecualikan dari analisis sensitivitas ini, sehingga tersisa 598 citra. Kedua pengujian menghasilkan *permutation* $p=0,001$.

Target regresi pada *holdout* berasal dari prediksi DMS46, sehingga penurunan *error* tersebut belum memvalidasi material sebenarnya. Untuk memeriksa deskriptor DMS46 pada sumber lain, evaluasi 1.018 citra Bangladesh menghasilkan *macro AUROC* 0,732 dengan 95% CI [0,710–0,752] dan *macro AP* 0,501. AUROC yang melampaui 0,500 menunjukkan adanya sinyal pembeda terhadap empat *class* material sumber, walaupun logam masih memiliki AUROC terendah, yaitu 0,683. Karena *dataset* tidak menyediakan *ground truth* per piksel, hasil ini belum menilai ketepatan luas material yang diprediksi. Pembatasan ke ROI diuji karena anotasi Bangladesh menunjukkan lokasi objek yang dinilai. Namun, *macro AUROC* ROI sebesar 0,732 dibanding *rembg* 0,739 menghasilkan



DIKTISAINTEK
BERDAMPAK



selisih berpasangan $-0,008$ dengan CI $[-0,015-0,0004]$. Karena interval tersebut mencakup nol, hasil ini belum mendukung peningkatan AUROC melalui ROI.

Profil deskriptif Fusion-L2 pada 4.179 citra membantu membaca hubungan antara kelompok perangkat dan material yang tampak. Pada kelompok *printer*, rata-rata area prediksi plastik mencapai 54,2% dibanding 33,0% pada seluruh data. Kelompok layar memiliki area prediksi kaca 28,4% dibanding 10,0% secara keseluruhan, sedangkan kategori lainnya masih mencakup rata-rata 48,9% area pada kelompok baterai. Gambar 8 memperlihatkan keluaran DMS46 pada dua citra internal, yaitu *printer* dan TV, serta dua citra Bangladesh, yaitu *keyboard* dan PCB. Profil pada citra internal dihitung dari seluruh gambar, sedangkan profil Bangladesh dihitung dari area anotasi objek. Contoh tersebut membantu membaca prediksi model, tetapi tidak mewakili seluruh anggota *cluster* atau komposisi material sesungguhnya.



Gambar 8. Contoh citra internal dan Bangladesh beserta profil material visual prediksi DMS46 pada partisi Fusion-L2.

Keterbatasan Penelitian

Meski penyeragaman *input* menurunkan AUC asal foto, NMI sekitar 0,16 menunjukkan bahwa proses akuisisi masih berkaitan dengan *cluster*. Pemeriksaan data juga menemukan enam pasangan citra *byte-identik* yang melintasi *discovery* dan *holdout* internal. Pasangan tersebut mengurangi independensi evaluasi *holdout*, tetapi besar pengaruhnya terhadap skor belum diukur. Cakupan data turut dibatasi oleh 200 citra *data test* yang masuk berdasarkan prediksi *electronic*, bukan *label* panitia, sementara kemungkinan *near-duplicate* antara data internal dan Bangladesh belum disingkirkan. Validasi stabilitas 100 *seed* dan adaptasi chooseR dilakukan pada *fused* K-Means, sehingga tingkat pengujiannya belum setara dengan semua alternatif. Perbandingan *single-view* serta set empat dan delapan *view* juga belum mengisolasi kontribusi tiap *backbone* dalam *fusion* final. Di sisi data, *ground truth* fungsi untuk seluruh citra internal



DIKTISAINTEK
BERDAMPAK



dan material per piksel belum tersedia. Banyak foto memperlihatkan produk utuh atau tampilan katalog, sehingga hasil penelitian belum menunjukkan kondisi limbah maupun keberhasilan pemilahan fisik.

PENUTUP

Penelitian ini menilai pengelompokan perangkat dari *multi-view frozen embedding* serta kaitannya dengan material visual yang diprediksi Apple DMS46. Pada data internal, *resize* dan *re-encoding* JPEG seragam menurunkan AUC asal citra SigLIP2 dari 0,993 menjadi 0,875. Adaptasi chooseR memilih $K=12$ dalam rentang $K=12$ hingga 16, dengan rata-rata ARI terhadap *medoid* 0,99747 pada 100 *seed*. K-Means memberi *silhouette* yang sebanding dengan PAM dan MCSF pada konfigurasi yang dibandingkan. Contoh dekat *centroid* memperlihatkan pola *mouse*, *keyboard*, serta tumpukan perangkat. Pada resolusi lebih tinggi, sebagian pemecahan *cluster* bertahan saat sampel berubah, sementara yang lain lebih sensitif.

Pada sumber eksternal Bangladesh, Fusion-L2 $K=12$ mencapai *strict Macro Top-1* sebesar 0,888 untuk empat *class* perangkat, lebih tinggi secara agregat daripada RADIO. Informasi *cluster* juga menurunkan *error* prediksi deskriptor material pada *holdout* internal sebesar 11,45% setelah asal citra dan statistik akuisisi diperhitungkan. Dengan demikian, kelompok perangkat dan profil material visual berpotensi menjadi dua informasi awal untuk pemilahan, meskipun pengujian ini belum memvalidasi persis *medoid* Fusion, seluruh jenis perangkat pada data internal, atau komposisi material sesungguhnya.

Pengujian berikutnya perlu menyamakan konfigurasi *fusion* antarevaluasi, menangani duplikat lintas *split*, dan memperluas cakupan perangkat. Untuk menilai manfaat dalam pemilahan fisik, penelitian lanjutan juga memerlukan foto kondisi limbah dan pemeriksaan material di luar prediksi visual.

REFERENSI

Afrin, T., & Azmi, A. A. (2025). *Custom Bangladeshi E-Waste Image Dataset for Object Detection and Recognition (Version 1)* [Dataset]. Mendeley Data.
<https://doi.org/10.17632/77383kmdnw.1>



DIKTISAINTEK
BERDAMPAK



- Baldé, C. P., Kuehr, R., Yamamoto, T., McDonald, R., D'Angelo, E., Althaf, S., Bel, G., Deubzer, O., Fernandez-Cubillo, E., Forti, V., Gray, V., Herat, S., Honda, S., Iattoni, G., Khetriwal, D. S., Luda di Cortemiglia, V., Lobuntsova, Y., Nnorom, I., Pralat, N., & Wagner, M. (2024). *The global e-waste monitor 2024* (Edisi 2). ITU & UNITAR. <https://ewastemonitor.info/the-global-e-waste-monitor-2024/>
- Cai, B., Wang, X., Lu, G.-F., & Li, Z. (2026). Multi-hierarchical contrastive spectral fusion for multi-view clustering. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 39617–39626. Artikel resmi
- Ehrlich, M., Davis, L., Lim, S.-N., & Shrivastava, A. (2021). Analyzing and mitigating JPEG compression defects in deep learning. *Proceedings of the IEEE/CVF International Conference on Computer Vision Workshops*, 2357–2367. <https://doi.org/10.1109/ICCVW54120.2021.00267>
- Gadetsky, A., Jiang, Y., & Brbić, M. (2024). Let go of your labels with unsupervised transfer. *Proceedings of the 41st International Conference on Machine Learning*, 235, 14382–14407. <https://proceedings.mlr.press/v235/gadetsky24a.html>
- Gagolewski, M., Bartoszyk, M., & Cena, A. (2021). Are cluster validity measures (in)valid? *Information Sciences*, 581, 620–636. <https://doi.org/10.1016/j.ins.2021.10.004>
- Geirhos, R., Jacobsen, J.-H., Michaelis, C., Zemel, R., Brendel, W., Bethge, M., & Wichmann, F. A. (2020). Shortcut learning in deep neural networks. *Nature Machine Intelligence*, 2, 665–673. <https://doi.org/10.1038/s42256-020-00257-z>
- Jaipuria, N., Stevo, K., Zhang, X., Gaopande, M. L., Garcia, I. C., Jain, J., & Murali, V. N. (2022). deepPIC: Deep perceptual image clustering for identifying bias in vision datasets. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops*, 4792–4801. <https://doi.org/10.1109/CVPRW56347.2022.00526>
- Lloyd, S. P. (1982). Least squares quantization in PCM. *IEEE Transactions on Information Theory*, 28(2), 129–137. <https://doi.org/10.1109/TIT.1982.1056489>



DIKTISA INTEK
BERDAMPAK



- Oquab, M., Darcet, T., Moutakanni, T., Vo, H., Szafraniec, M., Khalidov, V., Fernandez, P., Haziza, D., Massa, F., El-Nouby, A., Assran, M., Ballas, N., Galuba, W., Howes, R., Huang, P.-Y., Li, S.-W., Misra, I., Rabbat, M., Sharma, V., ... Bojanowski, P. (2024). DINOv2: Learning robust visual features without supervision. *Transactions on Machine Learning Research*.
<https://arxiv.org/abs/2304.07193>
- Patterson-Cross, R. B., Levine, A. J., & Menon, V. (2021). Selecting single cell clustering parameter values using subsampling-based robustness metrics. *BMC Bioinformatics*, 22, Article 39. <https://doi.org/10.1186/s12859-021-03957-4>
- Rajeev, P. A., Dharewa, V., Lakshmi, D., Vishnuvarthan, G., Giri, J., Sathish, T., & Alrashoud, M. (2025). Advancing e-waste classification with customizable YOLO based deep learning models. *Scientific Reports*, 15, Article 18151.
<https://doi.org/10.1038/s41598-025-94772-x>
- Recht, B., Roelofs, R., Schmidt, L., & Shankar, V. (2019). Do ImageNet classifiers generalize to ImageNet? *Proceedings of the 36th International Conference on Machine Learning*, 97, 5389–5400.
<https://proceedings.mlr.press/v97/recht19a.html>
- Secretariat of the Basel Convention. (2025). *Revised guideline on environmentally sound material recovery and recycling of end-of-life computing equipment* (UNEP/CHW.17/INF/25/Rev.1). United Nations Environment Programme.
<https://www.basel.int/Portals/4/download.aspx?d=UNEP-CHW.17-INF-25-Rev.1.English.pdf>
- Tschannen, M., Gritsenko, A., Wang, X., Naeem, M. F., Alabdulmohsin, I., Parthasarathy, N., Evans, T., Beyer, L., Xia, Y., Mustafa, B., Hénaff, O., Harmsen, J., Steiner, A., & Zhai, X. (2025). *SigLIP 2: Multilingual vision-language encoders with improved semantic understanding, localization, and dense features* [Preprint]. arXiv. <https://arxiv.org/abs/2502.14786>
- Upchurch, P., & Niu, R. (2022). A dense material segmentation dataset for indoor and outdoor scene parsing. *Computer Vision – ECCV 2022*, 450–466.
https://doi.org/10.1007/978-3-031-20074-8_26



DIKTISAINTEK
BERDAMPAK



LAMPIRAN

Lampiran A Sensitivitas antarresolusi

Tabel A1. Perubahan *cluster* layar pada K=14 dan K=16

Transisi	Contain.	Jaccard q2,5	Proporsi <i>web</i>
K12 C10 → K14 C13	0,978	0,0045	0,832 → 0,827
K12 C10 → K14 C8	0,980	0,503	0,832 → 0,812
K12 C10 → K16 C5	0,979	0,936	0,832 → 0,814
K12 C10 → K16 C12	0,985	0,955	0,832 → 0,839


Containment adalah proporsi anggota *cluster* pada K lebih tinggi yang berasal dari satu *cluster* pada K lebih rendah, bukan *purity* terhadap *ground truth*. Pada K=14, dua pecahan layar sensitif terhadap *subsampling*. Pada K=16, dua pecahan layar lebih stabil dan contoh dekat *centroid* memperlihatkan bentuk tabung dan layar datar. Proporsi *web* yang mirip tidak menghilangkan kemungkinan pengaruh akuisisi lain.

Lampiran B Parameter dan *source code* inti

Implementasi dan sumber eksperimen tersedia di repositori GitHub

Reproduksi dari nol memerlukan *dataset*, *embedding*, dan *checkpoint* yang tidak seluruhnya disertakan.

Lampiran C Contoh pemecahan *cluster* layar



Gambar C1. Contoh dekat *centroid cluster* layar K=16 yang memperlihatkan televisi tabung pada C05 (a) dan layar datar pada C12 (b).